Python语言

基于集成学习的信用卡发放预测模型

姓名： 马萱

学号： 23020040061

专业： 统计学（理）

学院： 统计与数学学院

2024 年 1 月 8 日

目录

1. 引言 **1**
- **1.1** 问题背景 1
- **1.2** 问题重述 1

2. 数据预处理 **2**
- **2.1** 数据说明 2
- **2.2** 缺失值处理 2
- **2.3** 特征构建 3
- **2.4** 样本不平衡处理:ADASYN 过采样 4

3. 特征选择：信用卡发放相关因素筛选 **6**
- **3.1** 相关性分析 6
- **3.2** 随机森林特征重要性筛选 7

4. 信用卡发放二分类预测模型 **9**
- **4.1** 训练集测试集划分 9
- **4.2** 基于决策树的信用卡发放客户画像 9
- **4.3** 随机森林 11
  - **4.3.1**确定树数量 11
  - **4.3.2**网格搜索超参数调优 11
- **4.4** BO-XGBoost 分类模型构建 13
  - **4.4.1**XGBoost 原理 13
  - **4.4.2**贝叶斯优化（BO） 14
- **4.5** Stacking 15
- **4.6** 其他机器学习模型 15
  - **4.6.1**梯度提升机（GBM） 15
  - **4.6.2**CatBoost 16
  - **4.6.3**AdaBoost 16
  - **4.6.4**LightGBM 16
- **4.7** 评价指标 17
- **4.8** 模型对比 18

5. 总结与展望 **21**

参考文献 **22**

图目录

图 2.1 原始数据展示 2
图 2.2 缺失值热图 2
图 3.1 相关系数热力图 6
图 3.2 随机森林流程图 7
图 3.3 随机森林变量重要性 8
图 4.1 训练集 X 与 Y 数据展示 9
图 4.2 剪枝后决策树可视化 10
图 4.3 随机森林的树数量选择 11
图 4.4 5 折交叉验证 12
图 4.5 调参可视化 12
图 4.6 贝叶斯优化结果 15
图 4.7 LightGBM 的叶子分裂策略 17
图 4.8 9 个模型混淆矩阵可视化 19
图 4.9 ROC 曲线 20

表目录

表 2.1　变量缺失情况 3
表 2.2　二分类变量编码表 3
表 2.3　多分类变量编码表 4
表 2.4　类别分布 5
表 4.1　目标变量取值说明 9
表 4.2　混淆矩阵说明 17
表 4.3　所有模型指标 18

1. 引言

1.1 问题背景

在金融领域，信用卡的发放决策是一个关键的业务环节。银行和金融机构在决定是否向申请人发放信用卡时，必须综合考虑多种因素，以降低信用风险同时也要确保业务的增长。

随着消费金融市场的迅猛发展，信用卡已成为现代金融体系中不可或缺的一部分。对于银行和金融机构来说，信用卡业务既是收入增长的重要来源，也是面临诸多挑战和风险的领域。银行在发放信用卡时，需要在风险控制和市场扩张之间找到平衡点。一方面，过于严格的信用审查可能导致失去潜在的好客户；另一方面，审查不足可能增加信用违约的风险。在这个背景下，银行面临的主要问题是如何精准评估申请人的信用状况，以决定是否向其发放信用卡。这个决策过程通常涉及对申请人的信用历史、收入状况、职业稳定性、现有债务、还款能力以及其他个人信息的综合评估。随着大数据和机器学习技术的发展，银行开始利用这些技术来提高信用评估的准确性和效率。

信用卡申请的评估涉及多种类型的数据，包括个人信息、财务状况、信用记录等。如何准确评估申请人的违约风险是一个挑战，需要精确的算法和模型。在处理个人财务数据时必须遵守相关的隐私保护和数据安全法律法规。在竞争激烈的市场中，银行需要制定合理的信用卡产品和信用策略以吸引并留住客户。如何有效利用大数据分析、人工智能和机器学习技术来优化信用卡审批流程。因此，银行和金融机构需要发展高效且可靠的信用评估系统，以便做出明智的信用卡发放决策，这不仅能够减少信用风险，也能提升客户满意度和市场竞争力。

1.2 问题重述

B：利用数据文件 all.xlsx 构建一个预测模型，用于预测是否批准发放信用卡。其中重要字段的说明已经在数据文件中给出，其余字段的说明可通过名字推测。要求：

通过数据分析，找出与是否批准发放信用卡相关的因素；

构建一个预测模型，用于预测是否批准发放信用卡；

在可能的情况下，对自己的模型进行分析解释。

2. 数据预处理

2.1 数据说明

原始数据维度为 1549*19，其中第二行为变量说明，共有 19 个特征，1548 条客户信息。最后一列“是否批准”为目前 1548 位客户申请信用卡的获批情况，第一列客户 ID 为唯一检索主键，其余列为该客户的个人信息，涵盖基本个人情况年龄、性别、年收入、教育情况、婚育情况等。

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S
客户ID	性别	有无汽车	有无财产	子女数	年收入(美元)	收入类型	教育水平	婚姻状况	住房类型	Birthday_count	就业时间	有无手机	有无工作电话号码	有无电话号码	有无登记email	职业类型	家庭成员数量	是否批准
						Pensioner：领取养老金，Commercial associate：商业收入，如销售、市场、财务咨询等，working：工作收入	Secondary / secondary special：中等专业教育，Lower secondary：初中			使用当天 （0）的倒数计数，-1表示昨天	就业开始日期。从当前天数（0）开始倒数。正值表示个人目前失业		0：没有登记工作电话号码，1：有登记工作电话号					0 表示申请已获批准，1 表示申请被拒绝
5008827	M	Y	Y	0	180000	Pensioner	Higher education	Married	House / apartment	-18772	365243	1	0	0	0		2	1
5009744	F	Y	N	0	315000	Commercial associate	Higher education	Married	House / apartment	-13557	-586	1	1	1	0		2	1
5009746	F	Y	N	0	315000	Commercial associate	Higher education	Married	House / apartment		-586	1	1	1	0		2	1
5009749	F	Y	N	0		Commercial associate	Higher education	Married	House / apartment	-13557	-586	1	1	1	0		2	1
5009752	F	Y	N	0	315000	Commercial associate	Higher education	Married	House / apartment	-13557	-586	1	1	1	0		2	1
5009753		Y	N	0	315000	Pensioner	Higher education	Married	House / apartment	-13557	-586	1	1	1	0		2	1
5009754	F	Y	N	0	315000	Commercial associate	Higher education	Married	House / apartment	-13557	-586	1	1	1	0		2	1
5009894	F	N	N	0	180000	Pensioner	Secondary / secondary special	Married	House / apartment	-22134	365243	1	0	0	0		2	1
5010864	M	Y	Y	1	450000	Commercial associate	Secondary / secondary special	Married	House / apartment	-18173	-678	1	0	1	1	Core staff	3	1
5010868	M	Y	Y	1	450000	Pensioner	Secondary / secondary special	Married	House / apartment	-18173	-678	1	0	1	1	Core staff	3	1
5010869	M	Y	Y	1	450000	Commercial associate	Secondary / secondary special	Single / not marrie	House / apartment	-18173	-678	1	0	1	1	Core staff	1	1
5018498	F	Y	Y	0	90000	Working	Secondary / secondary special	Married	House / apartment	-18950	-1002	1	1	1	0	Cooking staff	2	1
5018501	F	Y	Y	0		Working	Secondary / secondary special	Married	House / apartment	-18950	-1002	1	1	1	0	Cooking staff	2	1
5018503	F	Y	Y	0	90000	Working	Secondary / secondary special	Married	House / apartment	-18950	-1002	1	1	1	0	Cooking staff	2	1
5021303	M	N	N	1	472500	Pensioner	Higher education	Married	With parents	-8907	-913	1	0	0	1		3	1
5021310	M	N	Y	0	270000	Working	Secondary / secondary special	Married	House / apartment	-16896	-248	1	0	0	0	Laborers	2	1
5021314	M	N	Y	0	270000	Working	Secondary / secondary special	Single / not marrie	House / apartment	-16896	-248	1	0	0	0	Laborers	2	1
5021430	F	N	Y	0	126000	Commercial associate	Higher education	Single / not marrie	House / apartment	-18907	-2470	1	0	0	0	Sales staff	1	1
5021431	F	N	Y	0	126000	Commercial associate	Higher education	Single / not marrie	House / apartment	-18907	-2470	1	0	0	0	Sales staff	1	1
5021998	M	N	Y	0	90000	Pensioner	Secondary / secondary special	Married	House / apartment	-18863	-1644	1	0	0	1		2	1
5022053	M	N	N	0	202500	Working	Higher education	Single / not marrie	House / apartment	-12811	-4327	1	0	0	0		1	1
5022617	M	Y	Y	0	202500	Commercial associate	Secondary / secondary special	Civil marriage	House / apartment	-12022	-1674	1	0	0	1	Laborers	2	1
5023781	M	N	Y	0	157500	Commercial associate	Higher education	Civil marriage	House / apartment	-17800	-1086	1	0	0	0	Accountants	2	1

Sheet1

图 2.1 原始数据展示

2.2 缺失值处理

在建立预测模型前，需要保证数据的质量，下图展示了所有变量的缺失情况可视化，发现职业类型有大部分客户信息确缺失。

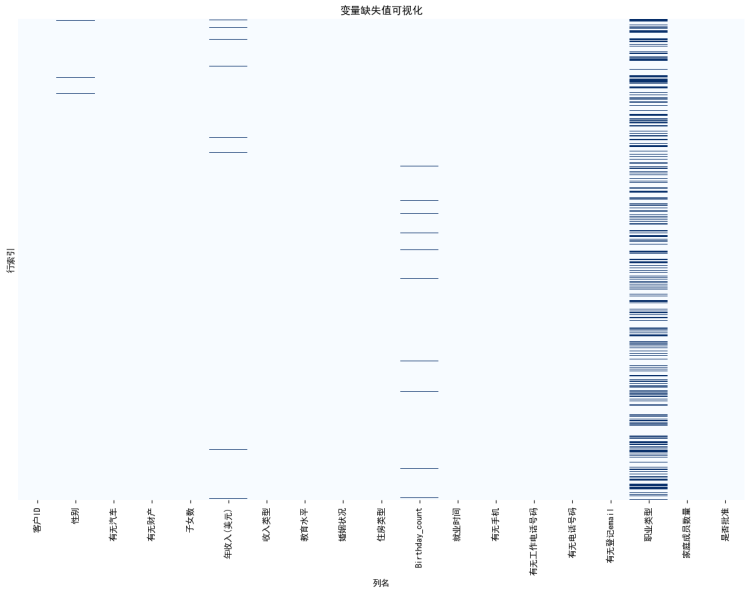

图 2.2 缺失值热图

含有缺失值的各变量具体缺失比例如表 2.1 所示，其中性别缺失数只有 7 条，删去这 7 条数据；年收入与 Birthday_count（年龄）占比不超过 1.5%，使用中位数对这二十多条客户信息进行填充；职业类型中空白占比为 31.52%，近三分之一，考虑到职业种类的繁多，将这部分客户的职业定义为一个新分类“其他”，赋值为 0。

表 2.1 变量缺失情况

变量	缺失数	缺失占比
性别	7	0.45%
年收入 (美元)	23	1.49%
Birthday_count	22	1.42%
职业类型	488	31.52%

2.3 特征构建

针对性别、有无汽车、有无财产这 3 类二分类变量赋值 0 和 1。在机器学习的分类预测中，将二分类输入变量赋值为 0 和 1，这种做法称为“二元编码”（Binary Encoding）。

机器学习模型通常更容易处理数值数据而非文本数据。将二分类变量（如“是”和“否”）转换为 0 和 1，可以将这些分类数据转化为机器学习算法可以理解和处理的数值形式。使用 0 和 1 可以避免认为数字之间存在某种数值上的顺序或大小关系，这两个数字通常被解释为“不存在”和“存在”的指示器。几乎所有的机器学习算法都可以处理数值特征，而不是所有算法都能直接处理非数值特征，通过将分类变量转换为 0 和 1，可以确保数据集与各种算法兼容。

表 2.2 二分类变量编码表

性别	编码	有无汽车	编码	有无财产	编码
M	0	N	0	N	0
F	1	Y	1	Y	1

本文使用模型多为树模型分类算法，不需要类别间有固定顺序。在树模型（如决策树、随机森林）中标签编码表现良好，因为这些模型能够处理整数编码而不会引入额外的假设。对于线性模型或神经网络，独热编码、二进制编码或嵌入编码更合适，因为这些模型对输入特征的数值关系更为敏感。故对下表多分类变量做标签编码处理，将每个类别分配一个唯一的整数。

表 2.3 多分类变量编码表

收入类型	编码	教育水平	编码	婚姻状况	编码
Pensioner	1	Higher education	1	Married	1
Commercial associate	2	Secondary / secondary specia	2	Single / not married	2
Working	3	Lower secondary	3	Civil marriage	3
State servant	4	Incomplete higher	4	Separated	4
		Academic degree	5	Widow	5
住房类型	编码	职业类型	编码	职业类型	编码
House / apartment	1	其他	0	High skill tech staff	10
With parents	2	Core staff	1	IT staff	11
Rented apartment	3	Cooking staff	2	Waiters/barmen staff	12
Municipal apartment	4	Laborers	3	Security staff	13
Co-op apartment	5	Sales staff	4	Medicine staff	14
Office apartment	6	Accountants	5	Private service staff	15
		Managers	6	HR staff	16
		Cleaning staff	7	Secretaries	17
		Drivers	8	Realty agents	18
		Low-skill Laborers	9		

2.4 样本不平衡处理:ADASYN 过采样

所给数据中，“是否批准”字段为 01 变量，用于标识信用卡发放是否批准情况，0 表示申请已获批准，1 表示申请被拒绝。在原始数据分类中，经计数，变量为“0”的个数为 1351 个，变量为“1”的个数为 168 个，因此正负样本数量不平衡，样本不平衡会使分类模型存在严重的偏向性，需要进行过采样，本题中选择 ADASYN 过采样对原数据进行处理，ADASYN 是在 SMOTE 算法的基础上进行改进的算法，根据每个少数类别样本的密度，生成更多的合成样本。

ADASYN（Adaptive Synthetic）过采样流程如下：

（1）计算样本数据不平衡的度

$$d = m_s/m_l \tag{2.1}$$

其中，d 表示不平衡的度，表示少数样本的数量，表示多数样本的数量。

（2）预设一个最大不平衡度，若小于预设的不平衡度，则继续进行过采样处理

（3）为少数类别样本计算需要合成的样本数量

$$G = (m_l - m_s) \times \beta \tag{2.2}$$

其中，为想要调整样本的程度，当时两类样本则实现平衡。

（4）计算调整比率 r

$$r = \Delta / k \tag{2.3}$$

其中，△ 为少数类别的 k 个近邻中属于少数类别的个数。

（5）计算需要生成的数量

$$n = r \cdot G \tag{2.4}$$

经过过采样，最终得到类别分布如下：

表 2.4 类别分布

类别	过采样前分布	过采样后分布
0	1351	1362
1	168	1351

可以看出最终过采样的效果较好，两个类别的样本数量匹配程度较高，可以进行下一步的建模计算。

3. 特征选择：信用卡发放相关因素筛选

3.1 相关性分析

斯皮尔曼相关系数，根据变量在数据内的位置来计算两个变量之间的相关性，取值范围是从-1 到 1，值越接近 1 正相关程度越大，计算公式如下：

$$\rho = 1 - \frac{6\sum d_i^2}{n(n^2-1)} \tag{3.1}$$

与皮尔逊系数相比，斯皮尔曼系数不要求数据满足连续性与服从特定分布的要求，特征相关系数热力图如图所示，发现与输出变量“是否批准”正相关的变量正相关程度均不高，只有 5 个变量大于 0，其中“有无手机”的相关系数值为空白，原因是所有客户都有手机，该变量对于是否批准信用卡发放没有区分度。

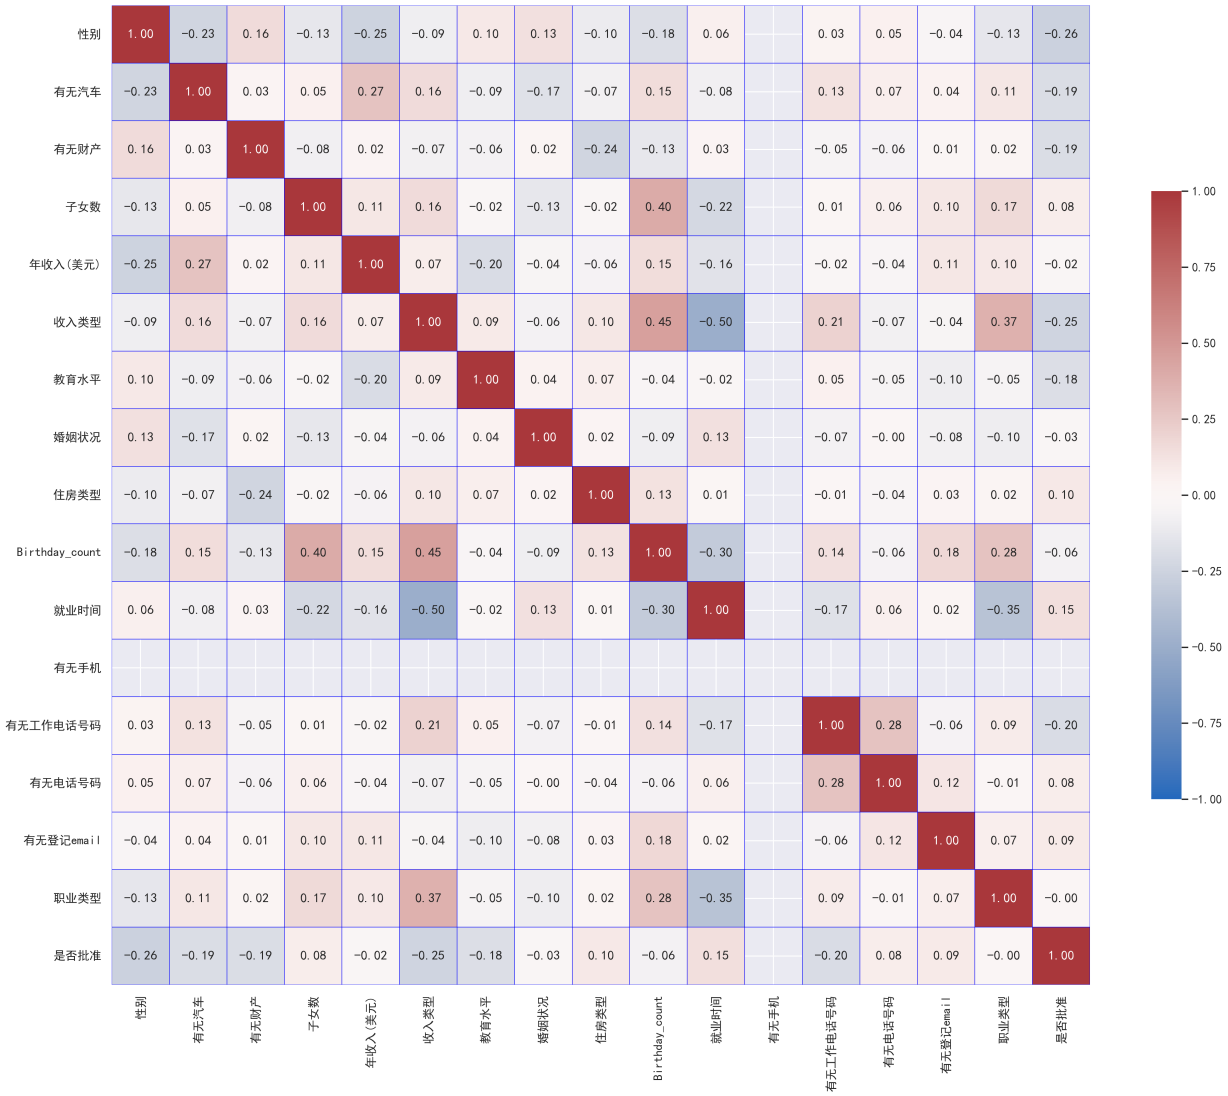

图 3.1 相关系数热力图

3.2 随机森林特征重要性筛选

为了进一步探索客户特征与是否批准信用卡发放的相关程度，选择嵌入方法：随机森林算法进行特征选择。

随机森林（Random forest，简称 RF）是由美国科学家 Leo Breiman 于 2001 年发表的一种机器学习算法[2]。作为一种新兴起、高度灵活的机器学习算法，其拥有泛的应用前景，在大量分类问题中具有极好的准确率。并且，随机森林算法自带特征筛选机制，即随机森林能够评估各个特征在相应问题上的重要性。在本题中，选择嵌入式特征选择方法随机森林进行特征重要性筛选，以期望得到前 15 个对是否最具有显著影响的变量。

随机森林以决策树为基础，将 K 个决策树作为基本分类器，通过集成学习的方式，将 K 个决策树的分类结果通过投票的方式输出结果，作为随机森林的输出。它的训练流程如图3.2所示。

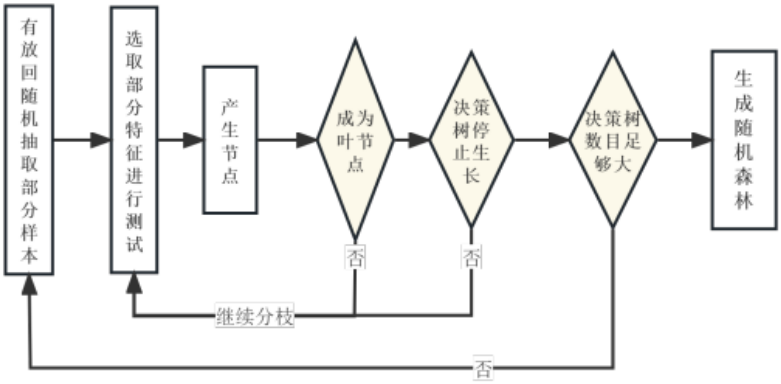

图 3.2 随机森林流程图

随机森林算法流程

输入: 训练集 D，树的数量 T，每个树的最大深度 max_depth

输出: 随机森林模型 Forest

Step 1. 初始化 Forest 为空

Step 2. For t = 1 到 T

从 D 中有放回地随机抽取与原始训练集大小相同的样本集，构建一颗决策树 D_t

从 F 中随机选择 k 个特征，构建特征子集，在子集中选择一个最优特征来构建树 F_t

在 (D_t, F_t) 上训练一个最大深度为 max_{depth} 的决策树 $Tree_t$

将 $Tree_t$ 添加到 Forest 中

Step 3. 返回所有树组成的随机森林

随机森林算法通过将样本分类的结果进行运算可以获得各个特征的特征重要性值。特征重要性是说明变量对于模型预测的贡献的重要指标，若某一特征重要性越大，表明该特征对预测结果的贡献越大；重要性越小，表明该特征对预测结果的贡献越小。随机森林算法中某一特征的重要性，是该特征在内部所有决策树重要性的平均值，而在决策树中，计

算某一个节点 k 的重要性：

$$n_k = w_k * G_k - w_{left} * G_{left} - w_{right} * G_{right} \tag{3.2}$$

$$f = \frac{\sum_j^i n_j}{\sum_i \sum_j n_k} \tag{3.3}$$

其中，n_k 代表 k 节点的重要性，设特征变量的重要性评分为 f, 假设有 i 个特征,j 个节点 w_k,w_{left},w_{right} 代表的 k 节点和左右节点中训练样本与总训练样本的比例;G_k,G_{left},G_{right} 的是 k 节点和左右子节点的不纯度。通过计算每一个节点的重要性后，代入公式即可得到某一特征的重要性。

基于上述随机森林特征重要性计算的方法，得到对是否发生血肿扩张的最具显著的特征，按照特征重要性从大到小进行排序，如下图所示：

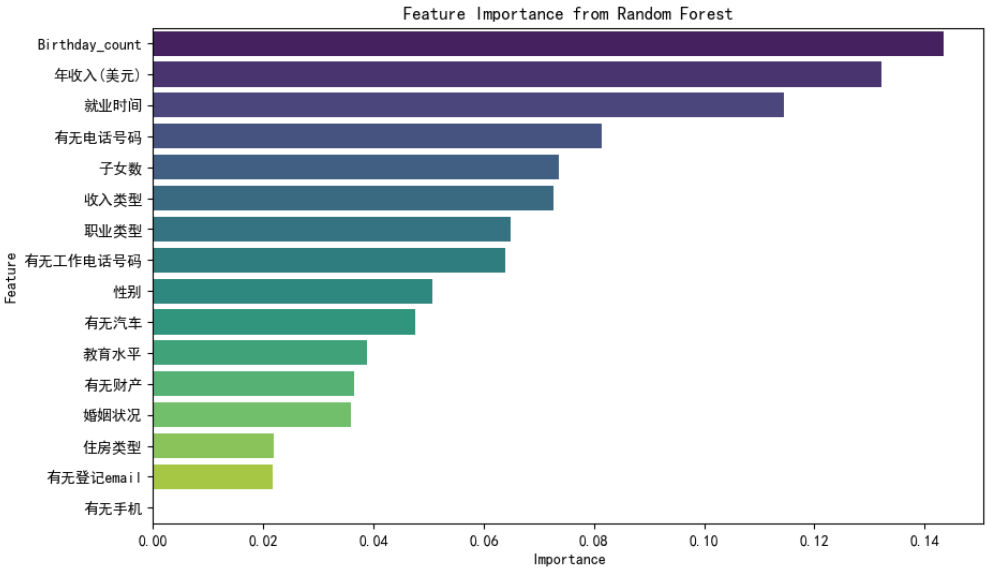

图 3.3 随机森林变量重要性

最终确定入选预测模型的特征有“Birthday_count”、“年收入 (美元)”、“就业时间”、“有无电话号码”、“收入类型”、“子女数”、“职业类型”、“性别”、“有无汽车”这 9 个特征。

4. 信用卡发放二分类预测模型

4.1 训练集测试集划分

基于随机抽样确保样本的代表性和独立性，将过采样后的 2713 条数据按照 8:2 比例划分训练集与测试集，最终确定 2170 个训练样本，543 个测试样本。

表 4.1 目标变量取值说明

取值	目标变量含义
0	申请获批准
1	申请被拒绝

训练集数据 X 与 y 部分数据如图 4.1 所示：

	Birthday_count	年收入(美元)	就业时间	有无电话号码	收入类型	子女数	职业类型	性别	有无汽车
556	-15256	157500.000000	-4491	0.0000	2	0.000000	3	1	0
1917	-17973	180000.000000	-5195	0.0000	2	2.314702	3	1	0
807	-14897	306000.000000	-3435	1.0000	2	0.000000	0	1	0
926	-10676	157500.000000	-2326	1.0000	2	1.000000	3	0	0
429	-17579	135000.000000	-1904	0.0000	3	0.000000	3	1	0
...	...	...	...	...	...	...	...	...	...
1147	-17532	90000.000000	-8044	0.0000	4	1.000000	14	1	1
2154	-19896	225000.000000	-1595	0.5718	3	0.000000	8	0	0
1766	-23522	73770.252495	365243	0.0000	1	0.000000	0	0	0
1122	-10728	135000.000000	-1619	1.0000	3	1.000000	5	1	0
1346	-19881	180000.000000	-7718	0.0000	3	0.000000	17	1	0

2170 rows × 9 columns

(a) Xtrain

```
y_train
```

```
556     0
1917    1
807     0
926     0
429     0
       ..
1147    0
2154    1
1766    1
1122    0
1346    0
Name: 是否批准, Length: 2170, dtype: int64
```

(b) ytrain

图 4.1 训练集 X 与 Y 数据展示

4.2 基于决策树的信用卡发放客户画像

决策树算法会从数据集中选择一个最优特征进行划分，以此将数据集分成若干个子集。选择最优特征的依据是信息增益、基尼指数等。划分完成后，每个子集都会对应一个决策节点，并按照同样的方式继续划分，直到满足停止条件。CART（Classification and Regression Trees）分类树是一种用于分类问题的决策树算法。它通过递归地分割数据集来构建树状结构，每个分割旨在尽可能地清晰地区分不同的类别。CART 分类树的基本原理和关键步骤：

（1）特征选择：在每个节点，CART 使用基尼不纯度（Gini Impurity）作为度量来选择最佳的分割特征。基尼不纯度是一种衡量数据集混乱程度的指标，其定义为：

$$Gini(p) = 1 - \sum_{i=1}^{J} p_i^2 \tag{4.1}$$

其中，p_i 是在数据集中第 i 类的相对频率，J 是类别的总数。基尼不纯度在所有类别完全混合时最大，当数据集只包含单一类别时最小。

（2）最佳分割点选择：对于每个特征，CART 算法会遍历所有可能的分割点，计算每个分割点导致的数据分割的基尼不纯度。选择那个能最大程度减小基尼不纯度的分割点作为最佳分割点。

（3）树的构建：使用选定的特征和分割点将数据集分割成两个子集，这个过程在每个子集上递归地进行，构建出决策树的分支。这个过程持续进行，直到满足某些停止条件，如达到最大深度、节点中的样本数小于最小样本数，或者节点的不纯度下降低于某个阈值。

（4）树的剪枝：为了防止过拟合，CART 在构建完整的树之后进行剪枝。剪枝是通过移除树的部分分支来实现的，目的是去除那些对模型泛化能力提升不大的分支。剪枝可以基于成本复杂度（cost-complexity）来进行，这涉及到一个平衡树的复杂度和模型在验证集上的性能的权衡。

CART 模型的关键参数设置:

- max_depth=3：指定了树的最大深度。树的深度是从根节点到叶节点的最长路径上的节点数量。在这个例子中，树的深度被限制在 3，这意味着树的每个路径最多只有 3 个节点，限制树的深度可以帮助防止模型过拟合。

- min_samples_split=5：决定了一个节点在被分割之前必须拥有的最小样本数。如果一个节点上的样本数量少于这个值，那么这个节点就不会被分割。只有当一个节点上至少有 5 个样本时，这个节点才会被考虑进行分割。

- min_samples_leaf=2：指定了一个叶节点必须拥有的最小样本数。叶节点是树的最终节点，不会进一步分割。这个参数设置为 2 意味着每个叶节点至少需要有 2 个样本，有助于确保树的每个叶节点有足够的数据量来做出可靠的分类决策，从而提高模型的泛化能力。

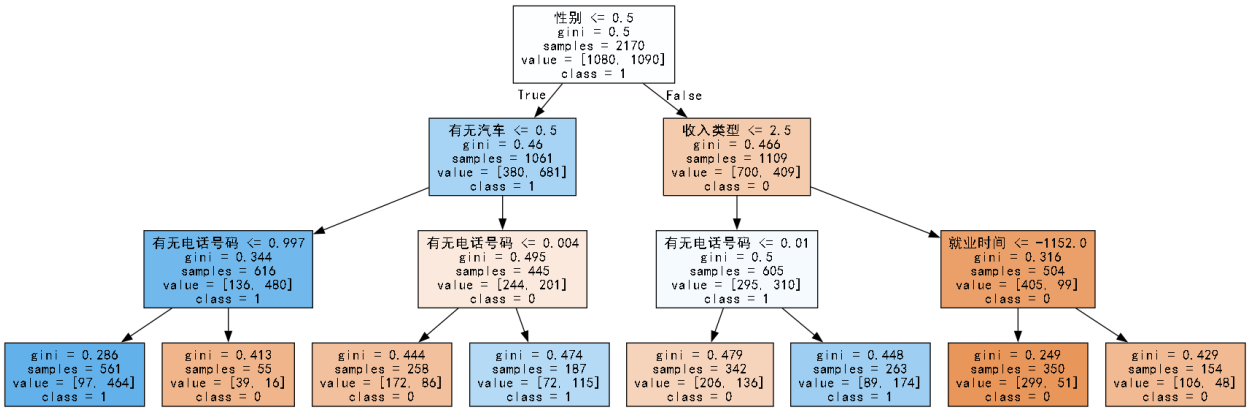

图 4.2 剪枝后决策树可视化

没有汽车，没有电话号码，收入类型为 Pensioner、Commercial associate 的女性客户不易被批准发放信用卡，该样本有 561 条。

就业时间在 1152 天以上，收入类型为 Working、State servant 的男性客户更容易获批发放信用卡，该样本有 350 条。

4.3 随机森林

4.3.1 确定树数量

随机森林（Random Forest）的 OOB（Out-Of-Bag）错判率是衡量随机森林性能的一个重要指标。OOB 错判率的计算基于 OOB 样本，即在构建每棵树时没有被选中的样本。如果随机森林的 OOB 错判率较低，那么可以认为模型具有较好的泛化能力。

（1）OOB 样本：在构建随机森林中的每棵树时，使用的是自助抽样（bootstrap sampling）。这意味着从原始数据集中重复抽取样本作为训练集，而不是每次都使用全部数据。在这个过程中，大约有三分之一的样本不会被选中用于某棵树的训练，这些未被选中的样本称为 OOB 样本。

（2）OOB 错误：对于每棵树，可以使用其 OOB 样本来测试树的性能。具体而言，我们使用这棵树对它的 OOB 样本进行预测，并记录预测错误的比例，这个比例被称为这棵树的 OOB 错误率。

（3）OOB 错判率：随机森林的 OOB 错判率是所有树的 OOB 错误率的平均值。它提供了一个无偏的性能估计，因为它是在未参与构建树的数据上计算的。

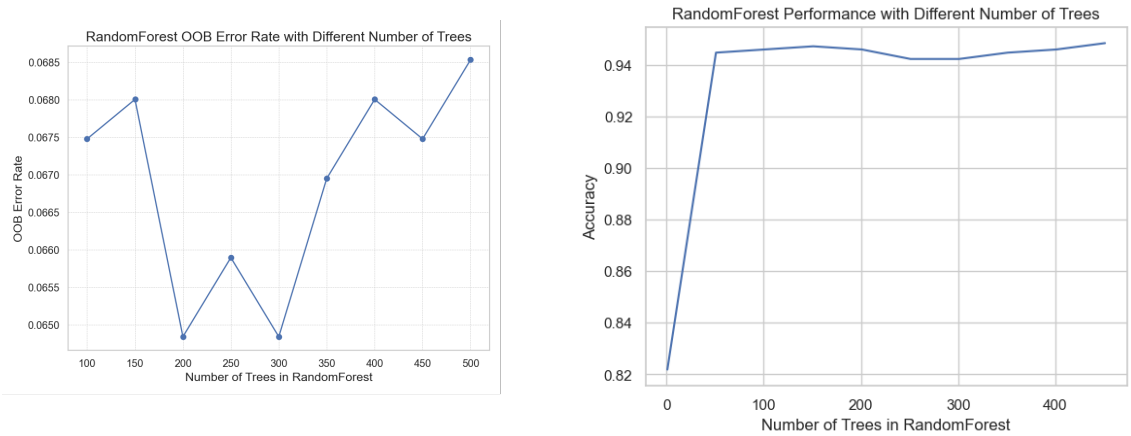

(a) OOB 错判率随机森林　　(b) 随机森林 acc

图 4.3 随机森林的树数量选择

图（a）显示当决策树树的数量为 200 和 300 时，OOB 错判率相对最低；图（b）显示随着树的数量增加，模型预测准确率提高，当树的数量为 200 时准确率约为 95%，最终确定随机森林模型参数 n_estimators=200。

4.3.2 网格搜索超参数调优

网格搜索（Grid Search）是一种用于超参数调优的方法，广泛应用于机器学习模型的优化中。它通过遍历指定的一系列超参数组合，来找到最优化模型性能的参数组合。

（1）定义参数网格：首先，为模型的需要调优的超参数 max_depth、min_samples_split、min_samples_leaf 定义一系列可能的值，这些值的集合构成了一个“网格”。

（2）系统遍历组合：网格搜索算法会系统地遍历所有这些参数组合。对于每一组超参数组合，它会构建一个新的模型实例，并在给定的训练数据上训练这个模型。

（3）性能评估：对于每个超参数组合训练出的模型，网格搜索使用交叉验证来评估其性能。交叉验证通常通过将数据集分为多个小子集（5 折交叉验证）来实现，每次使用其中一个子集作为验证集，其余作为训练集。

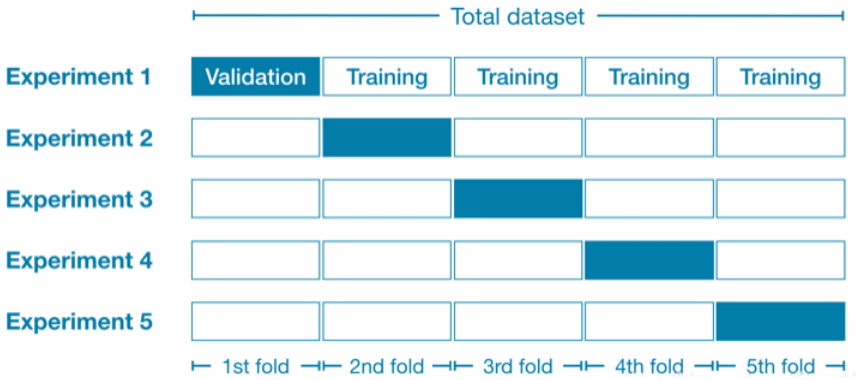

图 4.4 5 折交叉验证

（4）选择最优参数：在遍历所有参数组合并对每个组合进行评估后，网格搜索会选择准确率最好的参数组合。

（5）最优模型：最后，使用最优参数组合重新训练模型，这次通常会使用全部的训练数据。

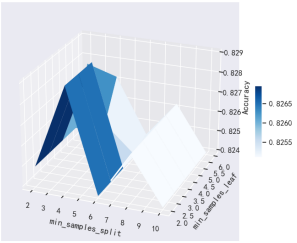

(a) 调参图 1

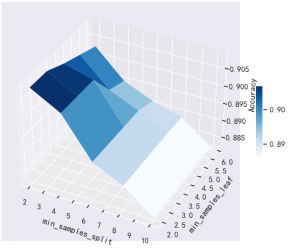

(b) 调参图 2

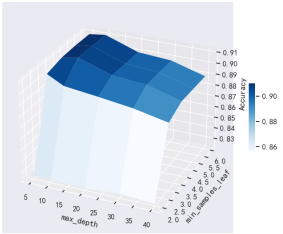

(c) 调参图 3

图 4.5 调参可视化

最终确定随机森林的超参数值如下：

- n_estimators=200
- max_depth=30
- min_samples_split=2

- min_samples_leaf=2

将调优后得到的超参数作为新模型的参数。

4.4 BO-XGBoost 分类模型构建

4.4.1 XGBoost 原理

XGBoost（Exstreme Gradient Boosting）极限梯度提升树模型，是一种集成学习算法，主要用于解决分类和回归问题。它是梯度提升树算法（GBDT）的扩展版本，可以进行大规模并行计算，在速度上和现有梯度提升相比具有较大提升。XGBoost 的核心原理是集成学习，通过构建多个弱学习器如决策树，组合成一个强大的模型。

GBDT 算法通过不断迭代决策树来提高模型的准确度，每一次迭代都会基于前一次迭代得到的结果来生成下一刻决策树，具体可以表示为：

$$f_i(x) = y - \sum_{k=1}^{i-1} f_k(x) \tag{4.2}$$

其中，$f_i(x)$ 是第 i 棵决策树需要拟合的函数，y 为实际值，x 为输入的变量。

最终，通过将所有决策树的预测结果进行加权结合，得到最终的预测结果。

分类回归树是一种二叉树，可以不断分裂。假设树的叶子节点是根据第 j 个特征值进行分裂，临界值为 s, 当特征值小于临界值时，样本为左子树；相反，为右子树。

$$R_{left}(j,s) = \left\{x \mid x^j \leq s\right\} \tag{4.3}$$

$$R_{right}(j,s) = \left\{x \mid x^j \geq s\right\} \tag{4.4}$$

在生成和训练了 K 棵树后，若想要对某一样本进行预测，可以在每棵树上得到叶子节点的得分，将得分累加起来就得到了样本的预测值。XGBoost 目标函数由损失函数和正则化项组成，损失函数主要用于描述模型拟合数据的程度。正则项用于控制模型的复杂度以及避免过拟合现象的发生，通过加入 L1、L2 正则项明显提高了模型的泛化能力，有利于防止过拟合。

$$\hat{y}_i = \sum_{k}^{K} f_k\left(x_i\right), f_k \in F \tag{4.5}$$

$$\text{obj}^{(t)} = \sum_{i=1}^{n} l(y_i, \hat{y}_i{}^{(t)}) + \sum_{i=1}^{t} \Omega(f_k) \tag{4.6}$$

其中 K 表示树的棵树，F 表示所有的回归树，f 为其中一棵树，$f_k\left(x_i\right)$ 为一棵树种叶子节点的得分，$\hat{y}_i{}^{(t)}$ 代表第 t 步的预测，$\sum_{i=1}^{t} \Omega(f_i)$ 是模型的正则项，降低模型的过拟合。精简后的目标函数为：

$$obj^{(\ell)} = \sum_{j=1}^{T} \left[G_j w_j + \frac{1}{2} \left(H_j + \lambda \right) w_j^2 \right] + \gamma T \tag{4.7}$$

G_j, H_j 是确定的量，上述精简的目标函数可以看作是叶子节点的一元二次函数，对其求导可得到：

$$w_j^* = -\frac{G_j}{H_j + \lambda} \tag{4.8}$$

$$obj^* = -\frac{1}{2} \sum_{j=1}^{T} \frac{G_j^2}{H_j + \lambda} + \lambda T \tag{4.9}$$

上述目标函数的最优值 obj^* 也叫打分函数，用于衡量回归树的好坏，值越小，树越好。我们可以用 obj^* 来选择最佳切分点，切分点的好坏衡量标准如下：

$$\text{Gain } = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{\left(G_L + G_R \right)^2}{H_L + H_R + \lambda} \right] - \gamma \tag{4.10}$$

$Gain$ 最大的切分点即最佳切分点，按照此公式继续切分节点，即可得到最佳的分类树，从而获得最佳的 XGBoost 模型。

4.4.2 贝叶斯优化（BO）

贝叶斯优化器主要应用于，可以快速到一个可以接受的超参数值，和网格搜索相比，优点是迭代次数少缺点是不容易找到全局最优解。

假设一组超参数组合为 $X = x_1, x_2, \ldots, x_n$，不同的超参数会得到不同的结果，BO 贝叶斯优化就是假设超参数与我们需要优化的损失函数是一个函数关系。例如我们想调 LightGBM 回归模型的树的最大深度的超参数，就把黑箱函数设置成 LightGBM 回归，自变量为超参数，因变量为 LightGBM 回归在训练集准确度，设置一个可以接受的黑箱函数因变量取值，例如 0.8，得到的超参数结果就是可以让 LightGBM 回归分类准确度超过 0.8 的一个超参数。

如公式(4.11)所示，在 X 的取值范围内找到 x

$$x^* = \underset{x \in X}{\operatorname{argmin}} f(x) \tag{4.11}$$

在一般的机器学习问题中，$f(x)$ 常为黑箱优化问题，在计算过程中会耗费大量的资源。采用贝叶斯优化可以解决这个问题，它的思想如下表所示, 其中 X 是我们需要寻找的超参数搜索空间，D 为数据集，S 为集合函数，M 是通过拟合数据集 D 得到的模型。

基于贝叶斯优化的序列模型
输入: f, X, S, M
初始化得到的数据集
$D \leftarrow$ 初始化样本 (f, x)
For $i \longleftarrow \lvert D \rvert$ to T do
$P(y/x, D)$ 世训练模型 (M, D);
$X_i \longleftarrow \operatorname{argmax}_{x \in X} S(x, p(y \mid x, D))$;
$Y_i \leftarrow F(x_i)$;
$\leftarrow D \cup (x_i, y_i)$.
结束

```
|   iter    |  target   | learni... | max_depth | min_ch... | n_esti... |
-------------------------------------------------------------------------
| 1         | 0.9032    | 0.1186    | 9.606     | 7.588     | 183.6     |
| 2         | 0.853     | 0.05525   | 3.248     | 1.523     | 261.2     |
| 3         | 0.9041    | 0.2902    | 9.761     | 8.786     | 184.2     |
| 4         | 0.8986    | 0.1793    | 8.911     | 9.98      | 121.6     |
| 5         | 0.8691    | 0.1878    | 5.634     | 9.78      | 60.49     |
| 6         | 0.847     | 0.3       | 2.0       | 10.0      | 152.5     |
| 7         | 0.9101    | 0.2542    | 9.491     | 4.15      | 201.1     |
=========================================================================
{'target': 0.9101280219262383, 'params': {'learning_rate': 0.2542418549566294, 'max_depth': 9.49098832223992, 'min_child_weigh
t': 4.150461241484944, 'n_estimators': 201.05541677659158}}
```

图 4.6 贝叶斯优化结果

4.5 Stacking

Stacking 是一种集成学习算法，通过训练多个初始学习器，本题中选用 AXGBoost、随机森林作为初始学习器，再将初始学习器作为输入投入到次级学习器中，本题中选用的次级学习器为线性回归模型，由此最终可以得到一个总的学习器进行分类预测。Stacking 集成了不同的模型进行训练，提高了最终模型的泛能力，更具鲁棒性，结合多个模型的优点进而提高性能。

4.6 其他机器学习模型

4.6.1 梯度提升机（GBM）

梯度提升机（Gradient Boosting Machine, GBM）是一种强大的机器学习算法，用于分类和回归问题。它基于提升（boosting）的思想，通过结合多个弱学习器来形成一个更强大的模型。GBM 的关键在于每一步都会添加一个新的弱学习器来纠正之前所有学习器的总预测误差。在二分类问题中，GBM 通常使用对数损失函数（logistic loss）作为其目标函数，二分类 GBM 的核心步骤：

（1）初始化：GBM 首先初始化一个模型。在二分类问题中，这通常是一个简单的模型（如一个决策树），它给出对每个实例的基本预测。这个初始预测可以是所有样本点的平均

值，或是一个简单的常数。

（2）计算负梯度（残差）：接着，对每个数据点计算损失函数（对数损失）的负梯度。在二分类问题中，这相当于计算每个数据点的残差（即实际值与预测值之间的差异）。

（3）训练弱学习器：根据这些负梯度（残差），训练一个新的弱学习器（通常是一个决策树）。这个弱学习器的目标是预测每个实例的负梯度。

（4）集成弱学习器：将新的弱学习器加入到现有模型中。这里的关键是确定弱学习器对最终预测的贡献程度，通常通过学习率（learning rate）参数来控制。

（5）重复步骤 2-4：重复以上步骤，每次迭代都会产生一个新的弱学习器，直到达到预设的迭代次数或者模型的性能不再显著提升。

输出最终模型：将所有迭代产生的弱学习器组合起来，形成最终的模型。在二分类问题中，最终模型的输出通常被转换为概率值（例如，使用逻辑函数），以表示每个实例属于正类的概率。

对于二分类问题，GBM 利用了对数损失函数来优化模型。这种损失函数非常适合概率估计，它强调了正确分类实例的重要性，并对那些难以分类的实例施加更大的惩罚。这种方法使得 GBM 在许多二分类问题上表现出色，尤其是在存在复杂非线性关系时。

4.6.2 CatBoost

CatBoost 的基础决策树是对称树，该算法通过对训练样本进行对称分类，也就是说每一步中，树都采用相同条件进行分类，再选择能够损失函数最小的特征进行分支。模型通过在不同的子训练集上进行模型训练和残差计算，降低了噪声，消除了梯度估计的偏倚，并有效地解决了预测偏差问题。通过组合类特征，能够挖掘出特征间的关联性，从而大大地丰富了特征的维度。

4.6.3 AdaBoost

AdaBoost 模型是最基础的 Boosting 模型，在模型训练过程中，多次挑选数据集中的关键分类特征变量，逐步训练弱分类器，并用适当的阈值筛选出最优弱分类器，最后将每次训练筛选出的最优弱分类器集合成一个强分类器。AdaBoost 模型的部分参数有:$n_estimators$，模型中弱学习器的数量，数量太多容易存在过拟合问题，数量太少容易发生欠拟合问题，本文设置为；为了确定弱学习器权重的度量，本文通过使用对样本集分类预测概率大小来作为权重。

4.6.4 LightGBM

GBDT (Gradient Boosting Decision Tree) 是机器学习中一个长盛不衰的模型，其主要思想是利用弱分类器（决策树）迭代训练以得到最优模型，该模型具有训练效果好、不易过拟合等优点。LightGBM 是一个实现 GBDT 算法的框架。LightGBM 与 GBDT 和 XGBoost 相似，把 Loss 函数的负梯度作为当前基学习器的残差来近似拟合新的学习器。残差由损失函数的泰勒展开式近似表示，正则化项用于控制模型的复杂度。但是 LightGBM 的最大特

点是使用叶子分裂策略代替 XGBoost 的水平分裂策略，只选择具有最大的分裂增益的节点进行分裂，从而避免部分增益较小节点的代价，LightGBM 的叶子分裂策略如图所示

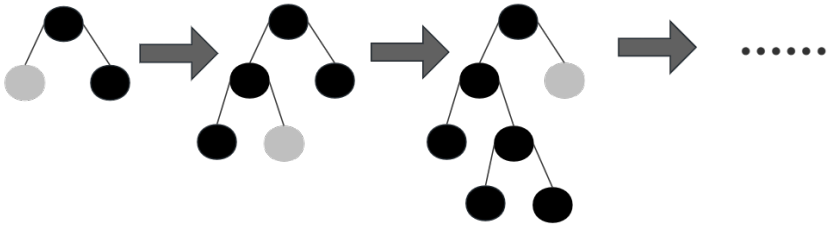

图 4.7 LightGBM 的叶子分裂策略

此外，LightGBM 使用基于直方图[?] 的决策树算法只保存特征的离散值而不使用 XGBoost，并使用精确算法中使用的预排序算法来减少内存的使用，加快模型的训练速度。直方图通过分段函数将连续值离散化为相应的 bin，如式（5.3）所示：

$$f_x = \begin{cases} 0, x \in [1, 10); \\ 1, x \in [10, 20); \\ 2, x \in [20, \infty) \end{cases} \tag{4.12}$$

对于式（5.2），将不小于 0 的连续特征分为 3 部分，特征分割点数减少为 3，即 bin 为 3，大大加快了训练速度。直方图包含每个 bin 样本中的梯度和每个 bin 中的样本数量，如式（5.4）和式（5.5）所示：

$$\mathrm{H[\ f.bins\ [i]] \cdot g+ = g_i} \tag{4.13}$$

$$\mathrm{H[\ f.bins\ [i]] \cdot n+ = 1} \tag{4.14}$$

每个面元的累积梯度包含一个一阶梯度和一个二阶梯度。

4.7 评价指标

在模型评估中，采用了精度 *Precision*、召回率 *Recall*、*F*1 分数、*Accuracy* 和混淆矩阵对模型进行评估，其中混淆矩阵种的各个值的说明如下表所示：

表 4.2 混淆矩阵说明

	预测正类别	预测负类别
真实正类别	TP	FN
真实负类别	FP	TN

精度 $Precision$：在所有判定为 postive 的结果中与真实情况吻合，即为 True 所占的概率，即准确率。

$$Precision = \frac{TP}{TP + FP} \tag{4.15}$$

召回率 $Recall$: 所有真实状态为 True 的实例中，有多少被成功判定为 Postive 的概率。即阳性的人有多少被检测出来了，检测率。

$$Recall = \frac{TP}{TP + FN} \tag{4.16}$$

$F1$ **分数**：是分类问题的一个衡量指标，为精确率和召回率的调和平均数，取值从 0 到 1，会更强调精确率和召回率较小的那个值。

$$F1 = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}} \tag{4.17}$$

准确率 $Accuracy$: 是指模型的准确率，即模型预测结果与真实结果的匹配度

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN} \tag{4.18}$$

4.8 模型对比

本文共建立 9 个分类模型，各指标见表，其中集成学习模型 Stacking 的预测准确率最高，为 95.95%。

表 4.3 所有模型评估指标表

模型	Accuracy	Precision	Recall	F1 Score
GBM	0.8950	0.91	0.88	0.89
LightGBM	0.9595	0.94	0.98	0.96
XGBoost	0.9558	0.94	0.97	0.96
BO-XGBoost	0.9521	0.93	0.98	0.95
CatBoost	0.9540	0.94	0.97	0.96
RF	0.9558	0.95	0.96	0.96
AdaBoost	0.8103	0.84	0.76	0.80
CART	0.7311	0.76	0.68	0.72
Stacking	**0.9595**	**0.96**	**0.96**	**0.96**

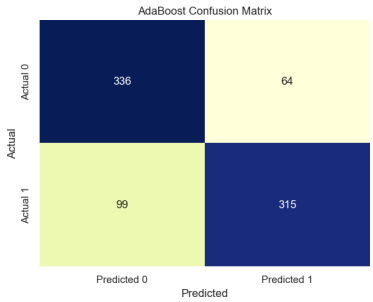

(a) adaboost

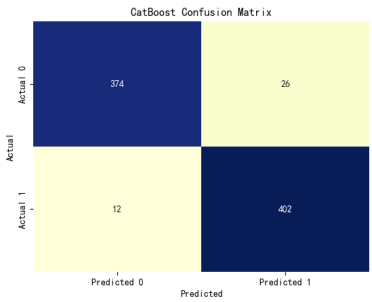

(b) catboost

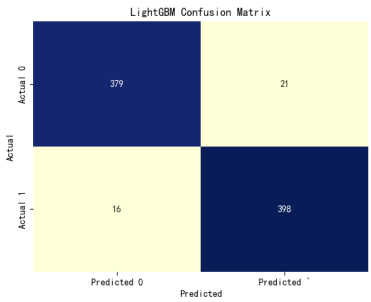

(c) LightGBM

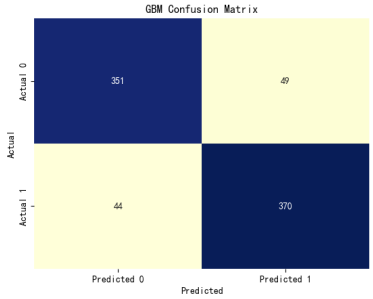

(d) GBM

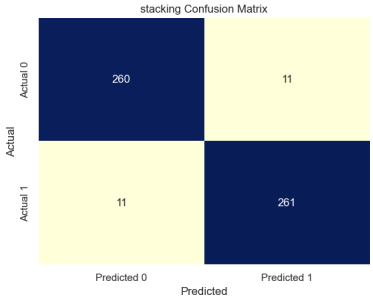

(e) stacking

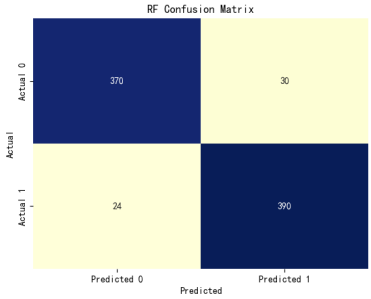

(f) rf

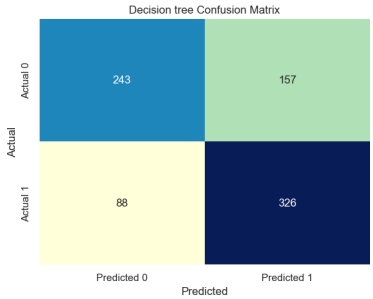

(g) 决策树

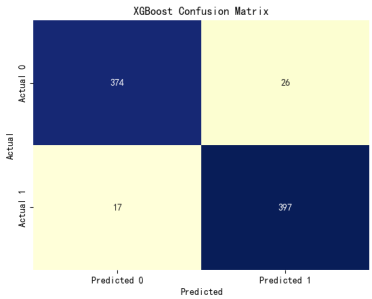

(h) XGB

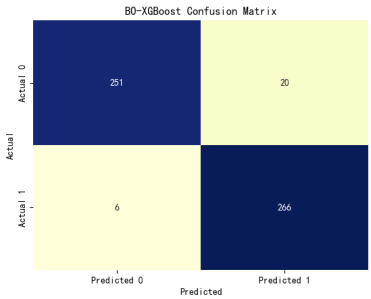

(i) BO-XGB

图 4.8 9 个模型混淆矩阵可视化

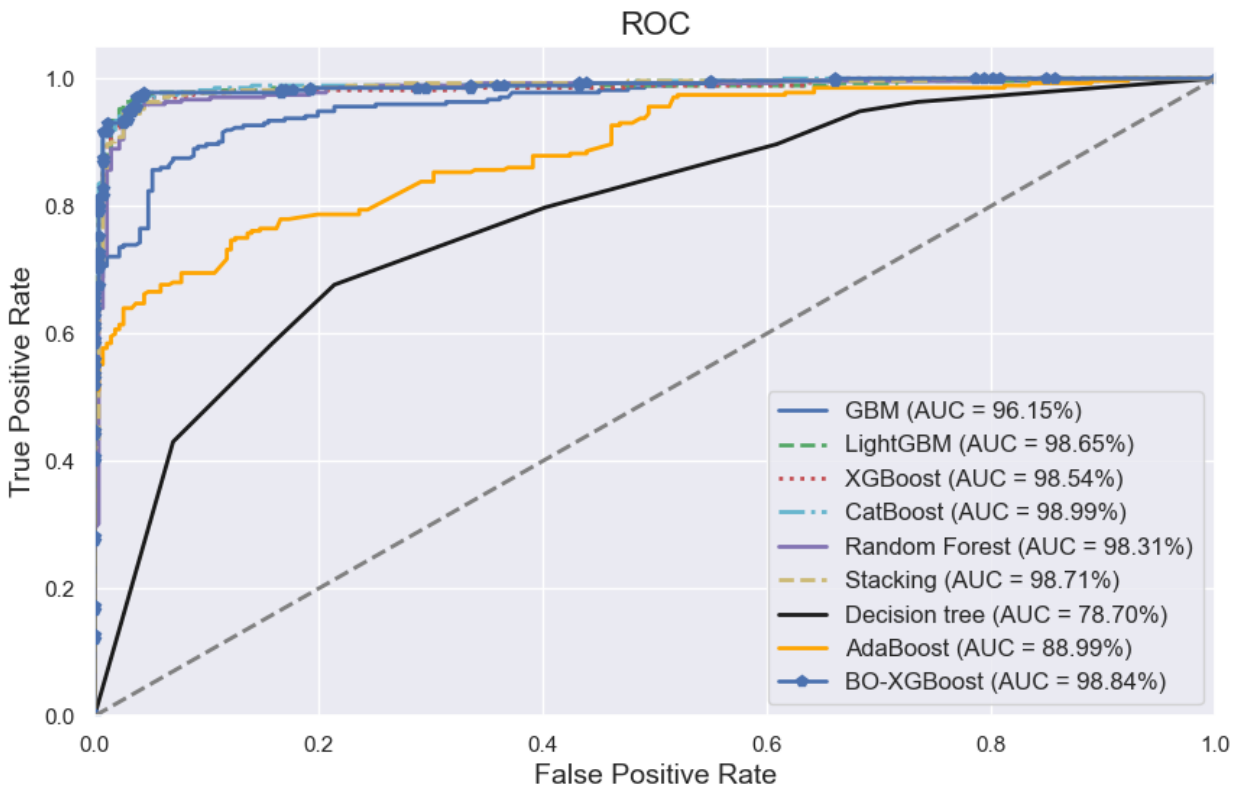
ROC
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
GBM (AUC = 96.15%)
LightGBM (AUC = 98.65%)
XGBoost (AUC = 98.54%)
CatBoost (AUC = 98.99%)
Random Forest (AUC = 98.31%)
Stacking (AUC = 98.71%)
Decision tree (AUC = 78.70%)
AdaBoost (AUC = 88.99%)
BO-XGBoost (AUC = 98.84%)

图 4.9 ROC 曲线

5. 总结与展望

在构建预测模型以预测是否批准发放信用卡的任务中，经过以下的步骤和分析：

- 数据理解和准备：首先，通过导入数据文件"all.xlsx" 并进行数据清洗，包括处理缺失值、异常值和重复值，确保了数据的质量。对数据进行了初步的探索性数据分析（EDA），包括查看基本信息、特征分布和相关性等，以找出与是否批准发放信用卡相关的因素。
- 特征工程：基于数据分析的结果和领域知识，选择了与目标变量相关的重要特征，并对它们进行了特征编码和缩放，以便用于机器学习模型的训练。
- 模型构建：使用多种机器学习模型，包括 XGBoost、AdaBoost、LightGBM、GBM、决策树、随机森林、Stacking 和 CatBoost，进行了二分类预测模型的构建。通过基于贝叶斯优化的参数调优，提高了模型的性能。
- 模型评估：使用测试集对模型性能进行了评估，包括准确度、精确度、召回率、F1 分数等指标。这些指标帮助了解模型的整体表现，并可以用于进一步改进模型。
- 模型解释：对模型的性能和特征重要性进行了分析解释，以了解模型对是否批准发放信用卡的预测影响。这可以通过 SHAP 值、特征重要性图等工具来实现。

未来可以进一步改进和扩展这个预测模型的能力。以下是一些展望和建议：

- 数据增强：如果有更多的数据可用，可以考虑使用更大的数据集来训练模型，以提高模型的泛化能力。
- 模型解释：深入研究模型的解释性，以便向业务决策者提供更多关于信用卡批准决策的信息。
- 实时预测：将模型部署到实际生产环境中，以进行实时信用卡批准预测。这需要考虑数据流和实时性能。
- 监控和维护：建立监控机制，定期评估模型性能，确保模型适应新的数据和变化。

参考文献

[1] Jorge R M ,Valentín M ,Francisco S G , et al. Machine Learning Approaches for Classification of Ultra High Carbon Steel Micrographs[J]. Key Engineering Materials,2023,6954.

[2] Kalidhasan R V ,Vasudevan R N ,Gowda V K . Improved learning by using a modified activation function of a Convolutional Neural Network in multi-spectral image classification[J]. Machine Learning with Applications,2023,14.